Санкт-Петербургский государственный университет
Кафедра системного программирования

Масштабируемость распределённого Galois на задачах анализа графов

Комбаев Ильхом, группа 23.Б11-мм

Санкт-Петербург
2026

Постановка задачи

Цель: оценить сильную масштабируемость распределённого Galois (D-Galois) по числу процессов и объяснить, от чего она зависит

Задачи:

- Собрать воспроизводимый стенд: Galois, графы, скрипты запуска и обработки
- Измерить BFS, SSSP, PageRank и подсчёт треугольников (TC) при $P = 1 \dots 6$ процессах на графах разной структуры
- Разложить время раунда по фазам (свой профилировщик) и объяснить результат

Сильная масштабируемость: граф фиксирован, растёт число процессов P. ускорение $S(P) = T(1)/T(P)$, идеал $S(P) = P$

Как считает D-Galois

Разбиение OEC: каждый процесс получает непрерывный блок номеров вершин (*мастера*) со всеми их исходящими рёбрами. Блоки подбираются так, чтобы рёбер было поровну

Конец ребра на чужом процессе — *зеркало*, локальная копия чужой вершины

RF (replication factor) — среднее число копий вершины по всем процессам

Раунд в режиме BSP (`--exec=Sync`):

1. счёт: процесс проходит своих мастеров
2. sync: зеркала отправляют изменения мастерам
3. Allreduce: осталась ли работа у кого-нибудь

Следующий раунд начинается, когда все процессы закончили предыдущий

Стенд и методика

Оборудование

- AMD Ryzen 5 5600X: 6 ядер, общий L3 32 МБ
- 32 ГБ DDR4, Fedora 42
- GCC 15.2, Open MPI 5.0.8
- Galois, коммит `b67f942`

Методика

- P MPI-процессов по 1 потоку, каждый на своём ядре
- Режим `--exec=Sync`, разбиение OEC
- Время — таймер `Timer_N` вокруг основного цикла алгоритма, без чтения и разбиения графа, максимум по процессам
- Медиана 5 прогонов (TC — 20), разброс $(\max - \min)/\text{медиана} < 1\%$

Ограничение: кластера нет, все процессы на одной машине — обмен идёт через общую память

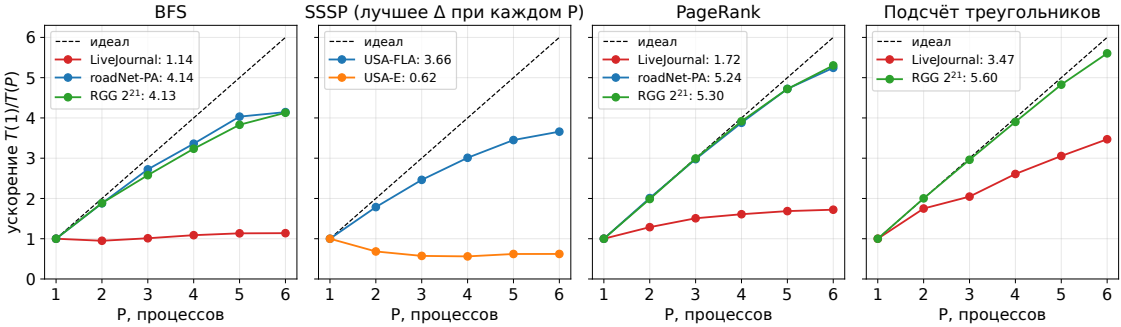
Графы

Граф	Вершин	Рёбер	Степень: ср. / макс.	Раундов BFS	RF при $P{=}6$
soc-LiveJournal1	4.8 M	69.0 M	14 / 20 293	16	3.05
roadNet-PA	1.1 M	3.1 M	2.8 / 9	595	1.02
rgg_n_2_21_s0	2.1 M	29.0 M	14 / 37	759	1.01
USA-road-d.FLA	1.1 M	2.7 M	2.5 / 8	—	1.02
USA-road-d.E	3.6 M	8.8 M	2.4 / 9	—	2.02

- LiveJournal: пользователи и подписки, есть *хабы* — 1% вершин держат 17% рёбер
- roadNet-PA: перекрёстки и дороги Пенсильвании
- RGG: 2^{21} случайных точек в квадрате, ребро — если точки ближе r
- USA-road-d: дороги Флориды (FLA) и востока США (E), вес ребра — длина

Для TC LiveJournal симметризован: 85.7 M рёбер

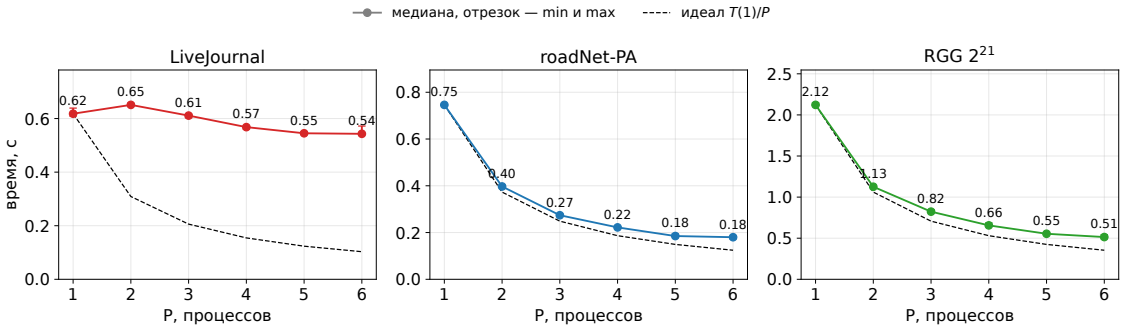
Ускорение всех алгоритмов



Ускорение $T(1)/T(P)$ при $P = 1 \dots 6$ процессах, пунктир — идеал $S = P$, в легенде — ускорение при $P = 6$. Для SSSP при каждом P взято лучшее Δ

- Графы без хабов, где у всех вершин близкая степень (дороги, RGG), ускоряются в 4–5.6 раза
- LiveJournal хуже всех в BFS, PageRank и TC, а SSSP на USA-E при росте P замедляется

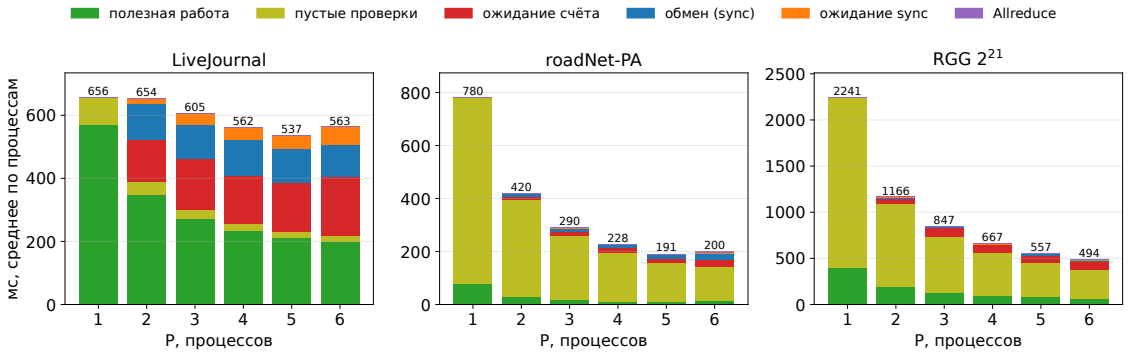
BFS: время



Время BFS при $P = 1 \dots 6$ процессах: точка — медиана, отрезок — min и max, пунктир — идеал $T(1)/P$

- roadNet-PA: 0.75 → 0.18 с, RGG: 2.12 → 0.51 с — ускорение 4.1
- LiveJournal: 0.62 → 0.54 с — почти не ускоряется

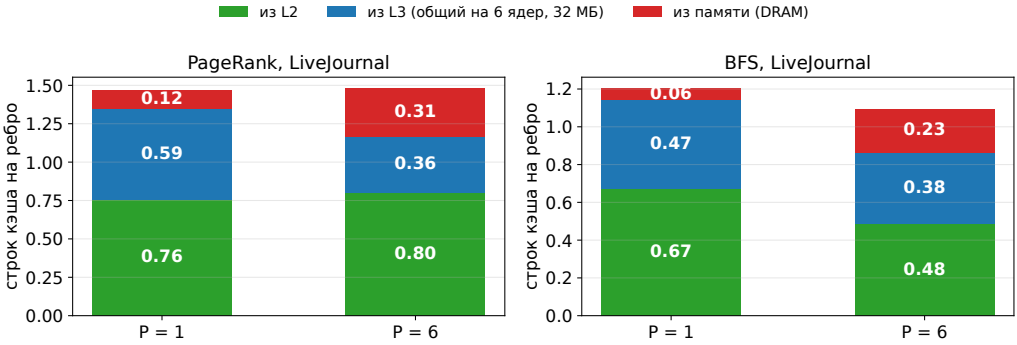
BFS: время по фазам при разном P



BFS (push) при $P = 1 \dots 6$: время фаз, среднее по процессам; над столбцом — сумма, мс. Данные — профилировщик фаз

- roadNet-PA и RGG: при $P = 1$ почти всё — пустые проверки, они делятся на P. К $P = 6$ растут ожидание и обмен
- LiveJournal: уже при $P = 2$ ожидание и обмен съедают выигрыш от деления работы
- Полезная работа LiveJournal при $P = 6$ — 200 мс, а не $571/6 \approx 95$ мс

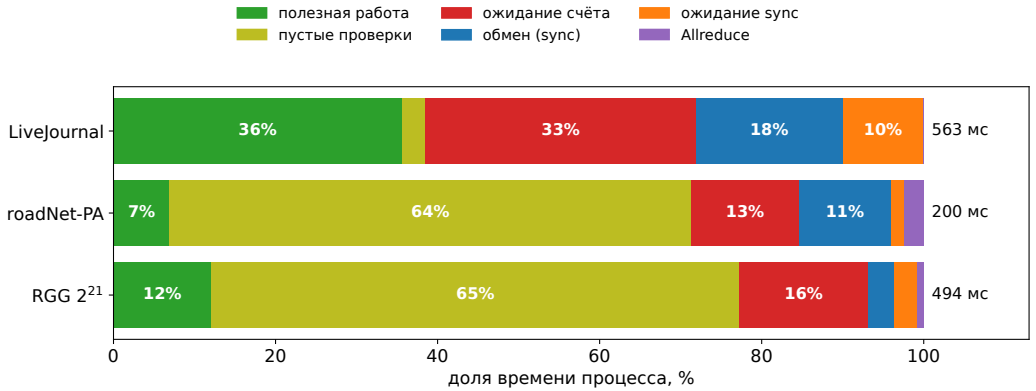
LiveJournal: промахи кэша при $P = 1$ и $P = 6$



Откуда процессор берёт данные при промахе L1, на одно обработанное ребро: счётчики процессора (`perf`), сумма по процессам, один прогон без чтения графа

- Промахов L1 на ребро столько же, но данные чаще идут из памяти, а не из L3: в PageRank 0.12 $\rightarrow$ 0.31 на ребро (в 2.6 раза), в BFS 0.06 $\rightarrow$ 0.23
- Шесть процессов делят один L3 на 32 МБ — рабочие данные каждого вытесняются, а обращение к памяти в несколько раз дороже попадания в L3

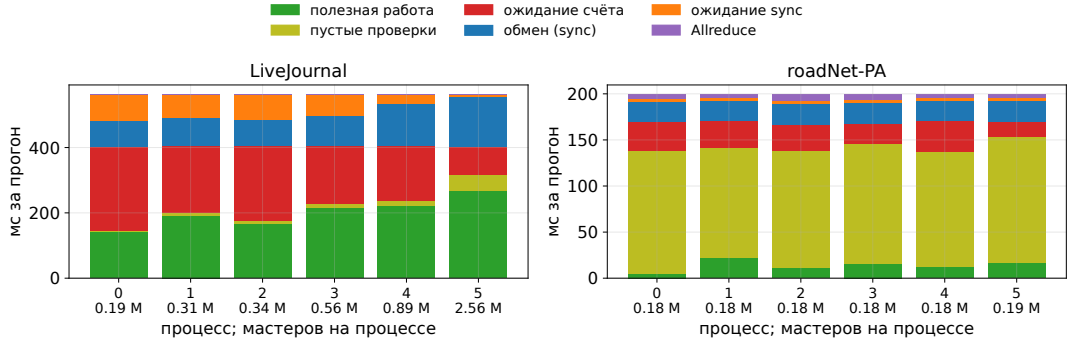
BFS: на что уходит время раунда



BFS (push) при $P = 6$: доли фаз во времени процесса, среднее по 6 процессам, справа — время прогона. Пустые проверки — проход по мастерам, у которых нет работы, ожидание — процесс закончил фазу и ждёт самого медленного

- Число раундов от P не зависит: 16, 595 и 759
- Дороги и RGG: 64–65% времени — пустые проверки: каждый раунд проходит *всех* мастеров, а фронт — сотни вершин. Проход делится на P, поэтому ускорение 4.1
- LiveJournal: полезная работа — треть, ещё треть — ожидание, итог 1.14

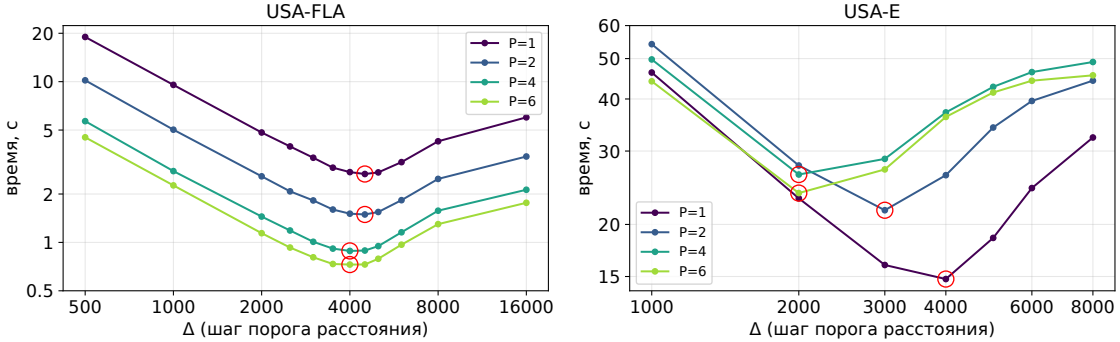
BFS: как работа делится между процессами



BFS при $P = 6$: время фаз на каждом процессе за прогон, под столбцом — число мастеров процесса

- OEC делит поровну рёбра (у LiveJournal по 11.5 M), а не вершины: последнему процессу достаются 2.56 M вершин с малой степенью из 4.85 M
- LiveJournal: процесс 5 считает 268 мс, процесс 0 — 141 мс, остальные ждут его (перекос $\max/\text{среднее} = 1.46$)
- roadNet-PA: вершины и рёбра поровну, перекос 1.08

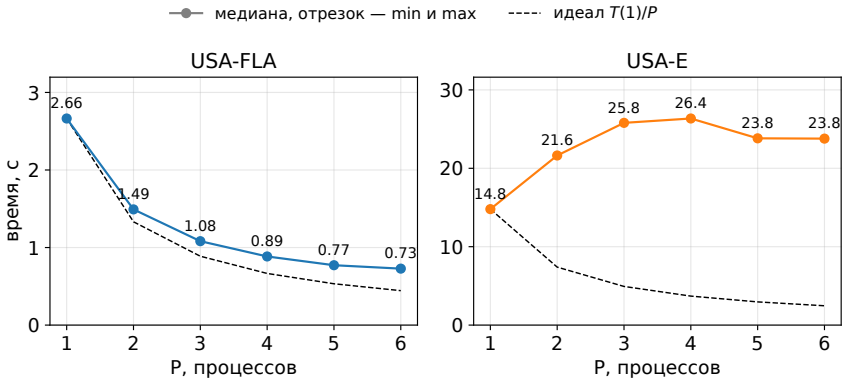
SSSP: выбор Δ



Время SSSP от Δ при $P = 1, 2, 4, 6$ (логарифмические оси), красный кружок — лучшее Δ при данном P

- За раунд обрабатываются вершины с расстоянием в полосе шириной Δ: малое Δ — много раундов, большое — лишняя работа
- Для сравнения по P берём лучшее Δ при каждом P
- USA-FLA: лучшее Δ почти не меняется (4000–4500), USA-E: сдвигается с 4000 при $P = 1$ до 2000 при $P \geq 4$, при $\Delta = 1000$ вдвое медленнее при любом P

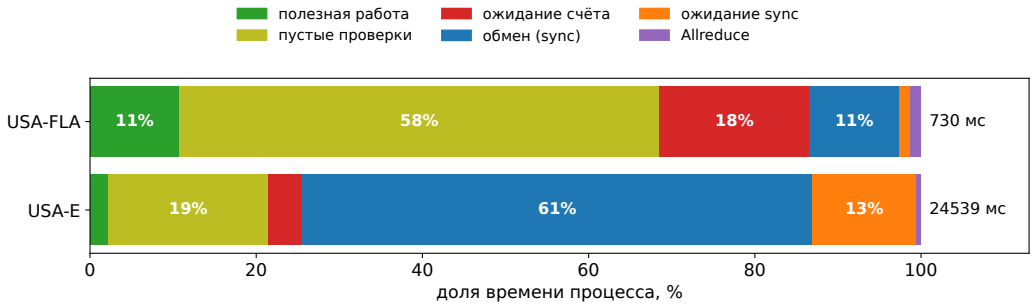
SSSP: время



Время SSSP при $P = 1 \dots 6$ процессах: точка — медиана, отрезок — min и max, пунктир — идеал $T(1)/P$, при каждом P взято лучшее Δ

- USA-FLA: 2.66 $\rightarrow$ 0.73 с, ускорение 3.66
- USA-E: 14.8 $\rightarrow$ 23.8 с — с ростом P медленнее

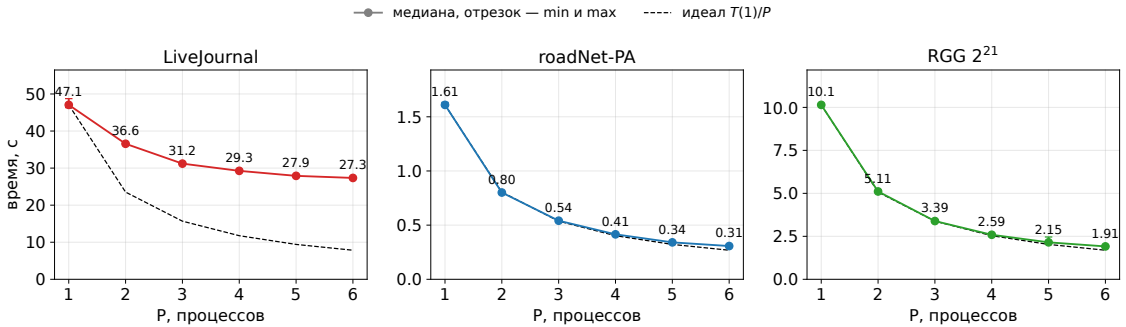
SSSP: на что уходит время раунда



SSSP (push) при $P = 6$ и лучшем Δ (FLA — 4000, E — 2000): доли фаз во времени процесса, среднее по 6 процессам, справа — время прогона. Пустые проверки — проход по мастерам, у которых нет работы, ожидание — процесс закончил фазу и ждёт самого медленного

- USA-FLA: 2120 раундов, 58% времени — пустые проверки, обмен 11%, ускорение 3.66
- USA-E: зеркал у процесса 310–880 тыс. (у FLA 1–8 тыс.), обмен — 61% времени. Шесть процессов медленнее одного (ускорение 0.62)

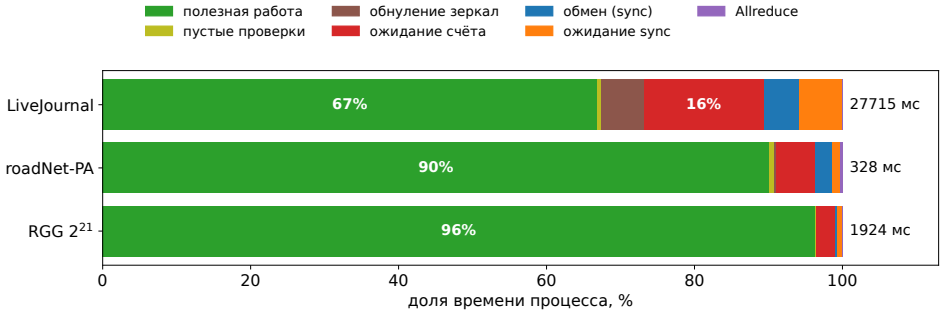
PageRank: время



Время PageRank при $P = 1 \dots 6$ процессах: точка — медиана, отрезок — min и max, пунктир — идеал $T(1)/P$

- roadNet-PA: 1.61 → 0.31 с, RGG: 10.1 → 1.91 с — ускорение 5.2–5.3
- LiveJournal: 47.1 → 27.3 с, ускорение 1.72

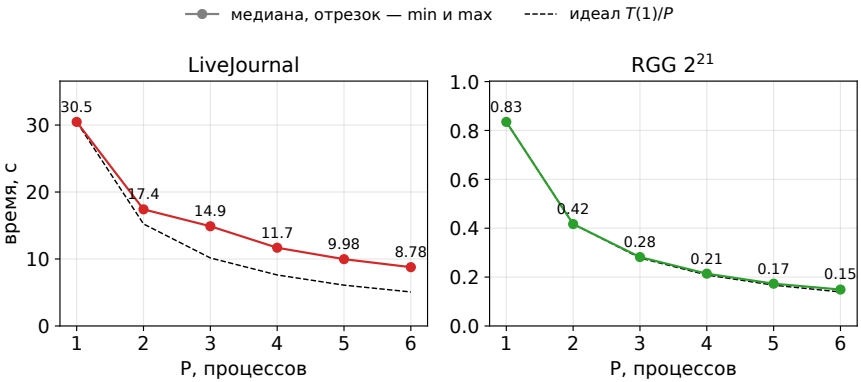
PageRank: на что уходит время раунда



PageRank (push) при $P = 6$: доли фаз во времени процесса, среднее по 6 процессам, справа — время прогона. Обнуление зеркал — сброс копий чужих вершин в начале каждого раунда

- Вершины активны, пока прирост ранга больше 10^{-6}: пустых проверок около 1%
- roadNet-PA и RGG: зеркал 2–5 тыс. на процесс, полезная работа 90–96%, ускорение 5.2–5.3
- LiveJournal: зеркал 1.2–1.8 M на процесс, обнуление и обмен — 11%, ожидание — 22%, ускорение 1.72. Рассылка дорожает из-за промахов кэша, как и в BFS

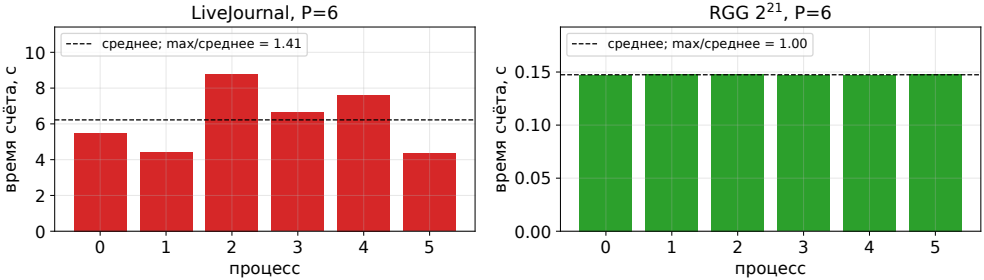
Подсчёт треугольников: время



Время подсчёта треугольников при $P = 1 \dots 6$ процессах: точка — медиана, отрезок — min и max, пунктир — идеал $T(1)/P$

- LiveJournal: 30.5 → 8.78 с, ускорение 3.47
- RGG: 0.83 → 0.15 с, ускорение 5.6

Подсчёт треугольников



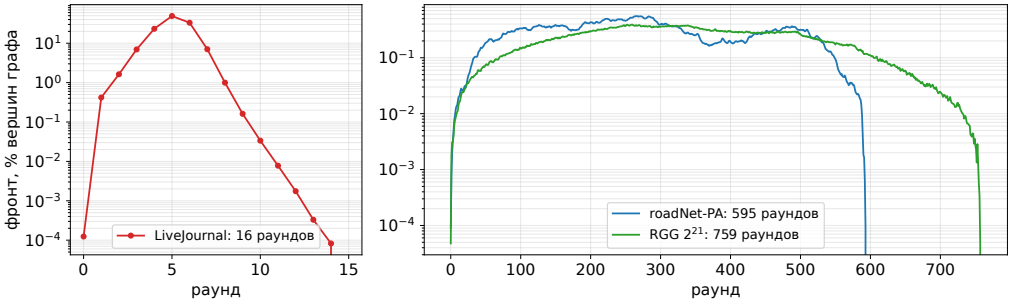
Время подсчёта на каждом процессе при $P = 6$ (медиана), пунктир — среднее по процессам

- Раундов и sync нет: один проход по мастерам и одно сложение (Allreduce)
- RGG: степени ровные, работа делится поровну — ускорение 5.6
- LiveJournal: работа вершины $\approx$ произведение её степени и степеней соседей, а мастера делятся блоками номеров — перекос 1.41, ускорение 3.47

Результаты

- Собран стенд: Galois, скрипты запуска и обработки, профилировщики фаз BFS, SSSP и PageRank (накладные расходы $< 1\%$)
- Измерены BFS, SSSP, PageRank и TC при $P = 1 \dots 6$ на 5 графах
- Найдено, что ограничивает масштабируемость:
  - проходы по всем вершинам и барьер в каждом из сотен раундов (BFS на дорогах и RGG)
  - OEC делит поровну рёбра, а не работу: перекос на графе с хабами (LiveJournal: BFS, PageRank, TC)
  - дорогой обмен в каждом раунде при большом RF (SSSP на USA-E: 61% времени)
  - общий L3 на все процессы: при $P = 6$ обращений в память на ребро в 2.6–3.8 раза больше (LiveJournal: BFS, PageRank)
- Ограничение: всё мерили на одной машине, на кластере обмен дороже

Дополнительно: ширина фронта BFS



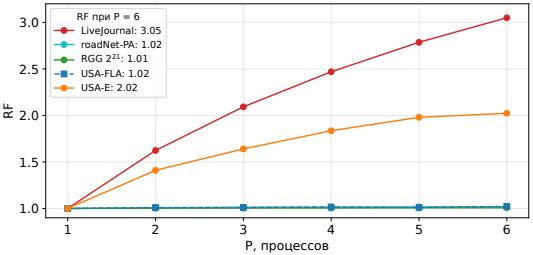
Фронт BFS — число вершин, которые в раунде рассылают расстояние, в процентах от всех вершин графа (логарифмическая ось). От P не зависит. Данные — профилировщик при $P = 6$

- LiveJournal: в пике активна половина графа (49%), медиана по раундам — 0.42%
- roadNet-PA и RGG: фронт не больше 0.6%, медиана 0.2–0.3% — остальные 99.7% мастеров в каждом раунде проходятся впустую

Дополнительно: таймеры Galois

- `StatTimer` копит время в микросекундах, а в статистику пишет целые миллисекунды и только ненулевой итог
- `Timer_N` создаётся один раз на прогон N вокруг основного цикла алгоритма — точность ± 1 мс
- Таймеры счёта (`do_all`) и sync создаются заново *в каждом раунде*: раунд короче 1 мс даёт 0 и не записывается. SSSP на FLA, $\Delta = 500$, $P = 6$: счёт «14 мс» за весь прогон
- Поэтому фазы раунда меряет свой профилировщик (`steady_clock`, мкс), ожидание выводится из меток времени: у процессов на одной машине общие часы

Дополнительно: RF по графам



Граф	P=2	3	4	5	6
LiveJournal	1.62	2.09	2.47	2.79	3.05
USA-E	1.41	1.64	1.84	1.98	2.02
USA-FLA	1.01	1.01	1.02	1.01	1.02
roadNet-PA	1.01	1.01	1.01	1.02	1.02
RGG 2^{21}	1.00	1.00	1.01	1.01	1.01

RF — среднее число копий вершины (мастер и зеркала) по всем процессам при разбиении OEC, $P = 1 \dots 6$; при $P = 1$ RF $= 1$

- LiveJournal: у хабов соседи на всех процессах, RF растёт до 3.05
- USA-E: номера вершин плохо ложатся на блоки, RF до 2.02
- Дороги FLA, roadNet-PA и RGG: соседи почти всегда в том же блоке номеров, RF ≤ 1.02